

# 時分割パターン学習ネットワークによる 高ノイズ耐性シングルピクセルイメージング

○佐藤千寛, 櫻井萌, 児玉晋二郎,  
中尾洸介, 星沢拓, 渡邊恵理子  
電気通信大学



謝辞: 本研究は, 学術変革領域研究(A)20H05888 の助成を受けたものである.



- 研究背景と目的
- 提案手法
- 学習条件
- シミュレーション結果
- まとめと今後の予定





多様なノイズによって、イメージング精度が低下してしまう

## 多様なノイズ環境下で高いノイズ耐性をもつイメージングシステムの構築

■ 深層学習による  
ノイズ耐性向上のための提案  
シングルピクセルイメージングと  
深層学習を融合


■ 提案手法を用いた  
再構成精度評価

モデル化した大気ゆらぎで再構成精度を評価



# Single-pixel imaging(SPI)と深層学習


## SPIの原理[1]



### 特徴

- ノイズ耐性を持つ
- ×測定時間がかかる

## Deep Convolutional Autoencoder Network(DCAN)[2]



### 特徴


- △大量のデータで学習
- パターン圧縮率向上
- ノイズ耐性向上

モデル化された  
ノイズに適用



[1] M. P. Edgar, et al., Nat. Photonics 13, 13–20 (2019). [2] C. F. Higham, et al.: Sci. Rep. 8, 2369 (2018).

## 大気ゆらぎの付与方法



## 課題

大気ゆらぎの付与は空間周波数領域で行われるため時間がかかる

Ex) 6万枚で学習する場合  
6万枚 × 1024パターン × 900エポック ≈ 553億回の操作が必要になる

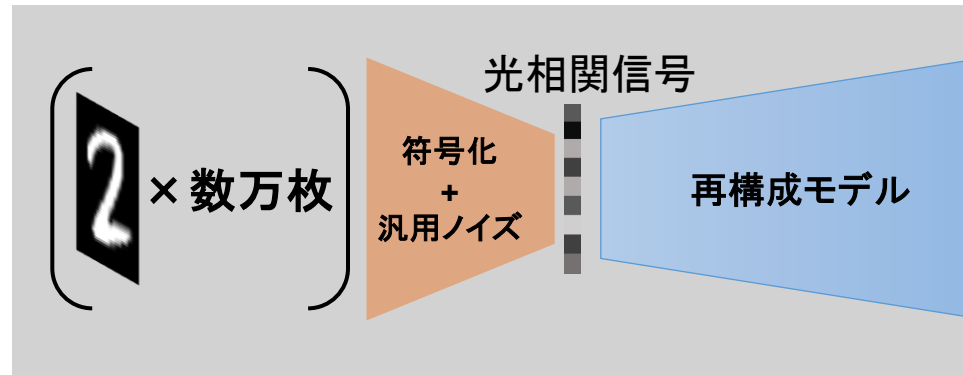
## 解決策

- 汎用ノイズで事前学習
- 大気ゆらぎでファインチューニング




## 目的: 実問題に即したノイズ環境でのノイズ耐性の向上

### 事前学習



### ファインチューニング



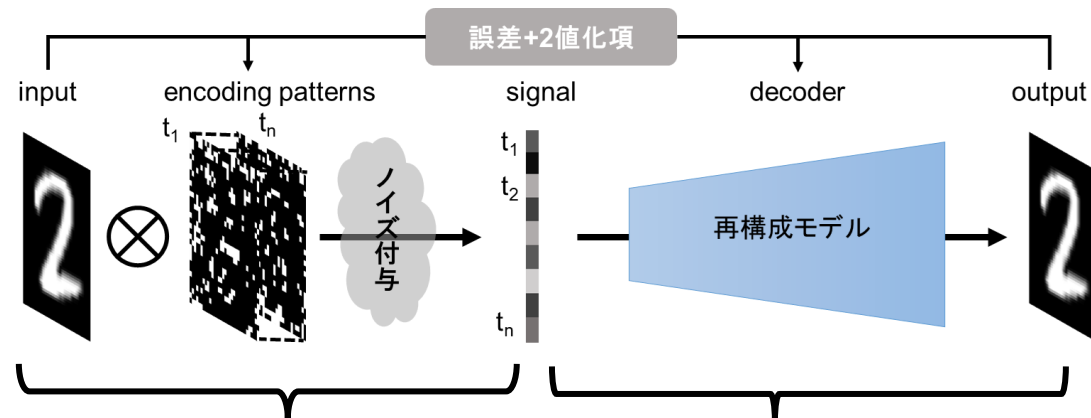
- 汎用ノイズを用いて大量のデータで事前学習
- 事前学習済みの再構成モデルを用いて実際の少数の光相関信号から再構成モデルを追加学習

計算コストの高い大気ゆらぎに対しても有用な手法を目指す




step  
01

TDPL Networkによる  
符号化パターンへの設計



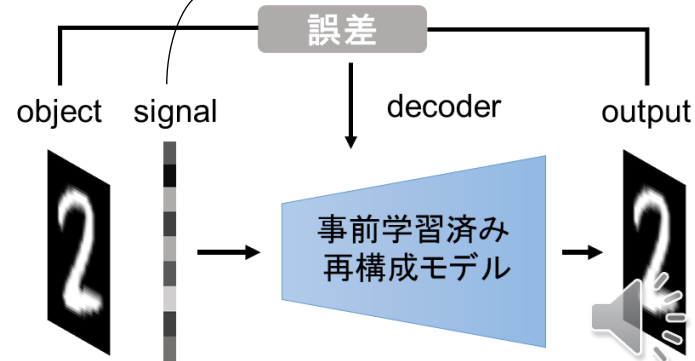
step  
02

設計した符号化パターンを  
使った光相関信号の取得

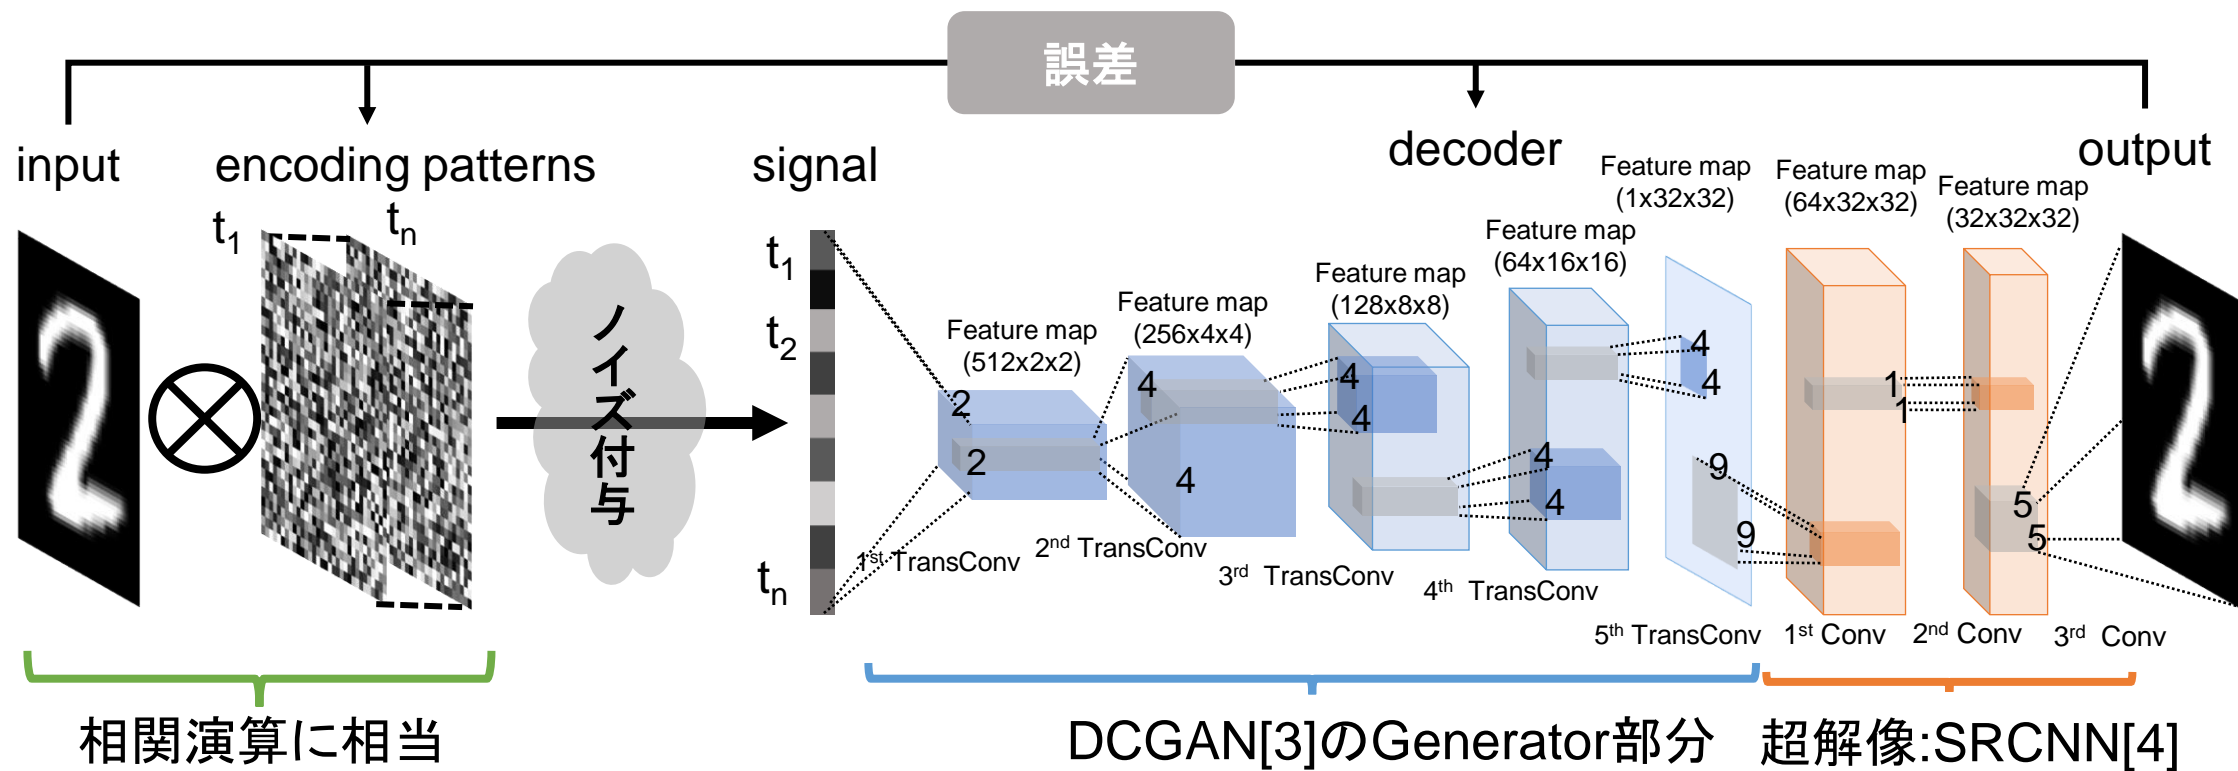


step  
03

光相関信号を入力し、  
再構成画像を追加で学習



# 提案手法: step1. 符号化パターンへの設計



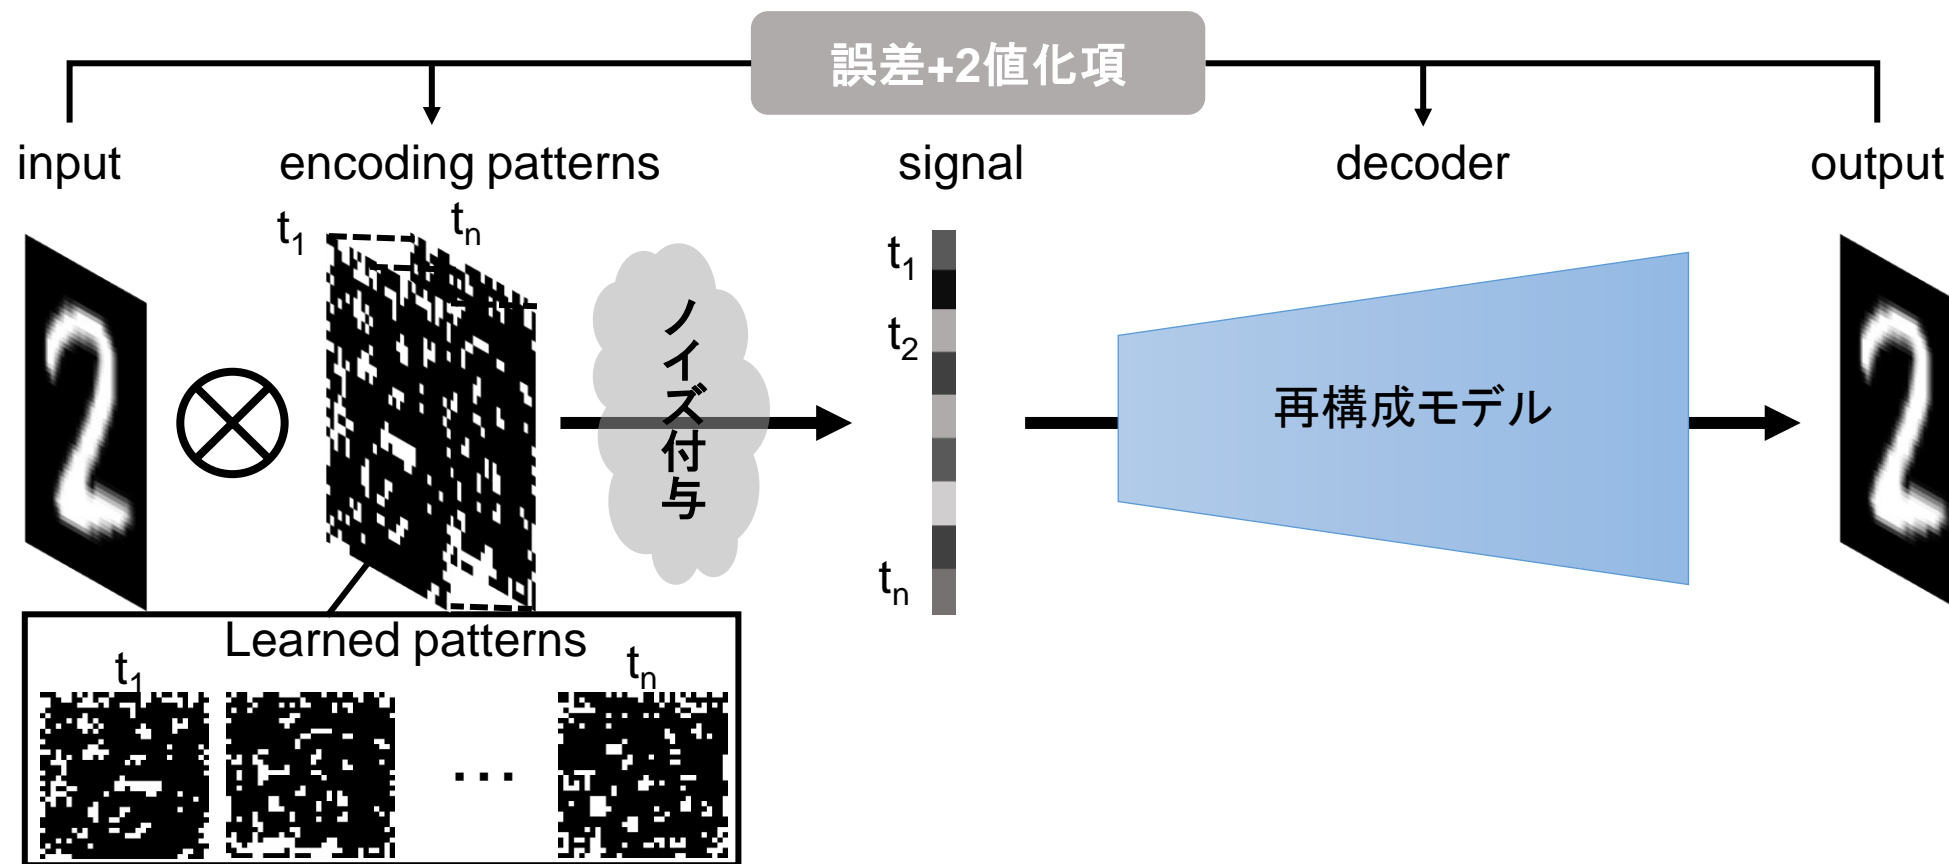
Step 1-1. 最初は2値化項を用いずに学習し, ネットワーク全体を最適化する



[3] A. Radford, et al., arXiv:1511.06434 (2015). [4] C. Dong, et al.: IEEE Trans. Pattern Anal. Mach, 38(2), 295-307(2016).



# 提案手法: step1. 符号化パターンへの設計




Step 1-1. 最初は2値化項を用いずに学習し, ネットワーク全体を最適化する

Step 1-2. 2値化を行う正則化項を導入し, 再びネットワークを最適化する

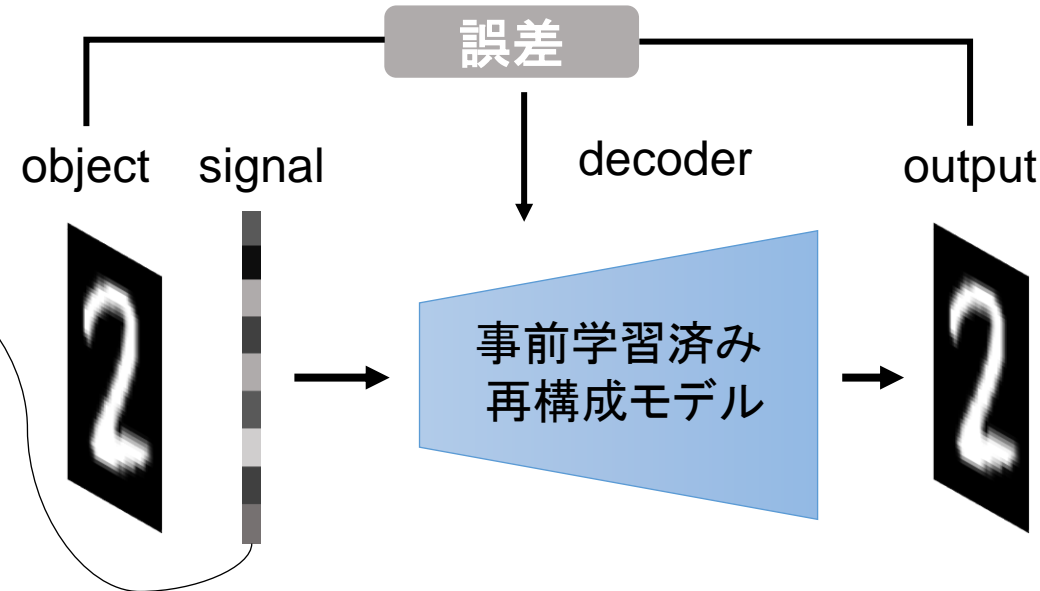


# 提案手法: step 2 & step 3

## Step 2. 光相関信号の取得



## Step 3. 再構成学習



Step 2. 設計した符号化パターンを用いてノイズ環境下で光信号を取得する

Step 3. 事前学習モデルを用いて, 取得した光信号でファインチューニング 

## パターン学習の条件

画像サイズ	32 × 32 pixel
データセット	種類 MNIST
	枚数 60,000 枚
設計パターン枚数	1024 枚
ホワイトレート	20%
訓練:検証	8:2
学習回数	1段階 700 epoch
	2段階 200 epoch
光信号ノイズ強度	3.0

## 最小二乗法による再構成式

$$\hat{x} = \arg \min_x \|Px - s'\|^2$$

$s'$ : ノイズ有りの光信号  
 $P$ : パターン行列  
 $x$ : 正解画像  
 $\hat{x}$ : 再構成画像

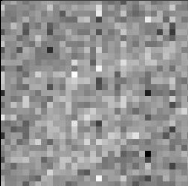
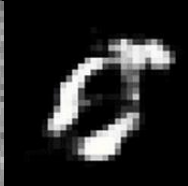
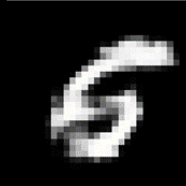
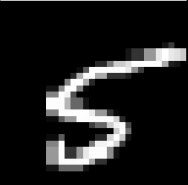
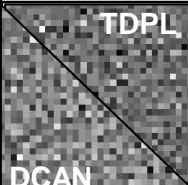

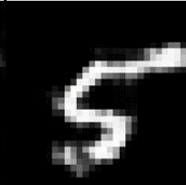
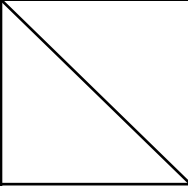


## 再構成学習の条件


画像サイズ	32 × 32 pixel
データセット	種類 MNIST
	枚数 2,048 枚
符号化 パターン	種類 設計パターン/ アダマール
	枚数 1024 枚
訓練:検証	8:2
学習回数	100 epoch
ノイズ強度 $D/r_0$	2

## 画像評価指標


SSIM	値が1に近いほど再構成精度が高い
RMSE	値が0に近いほど再構成精度が高い

# シミュレーション結果

	正解 画像	LS	DNN	
			DCAN	TDPL
Hadamard pattern				
		0.094	0.571	0.651
		0.466	0.217	0.201
Learned pattern				
		Ave. SSIM 0.015\0.016	0.788	0.806
		Ave. RMSE 0.498\0.500	0.140	0.132
Learned pattern + Fine tuning				
			0.835	0.839
			0.122	0.115



(a) SSIM



(b) RMSE



## まとめ

- 汎用的なノイズを用いて事前学習を行うことで、計算コストの高いノイズに対して有用な手法を提案した
- モデル化した大気ゆらぎを用いて提案手法の再構成精度を定量的に評価し、その有効性を確認した

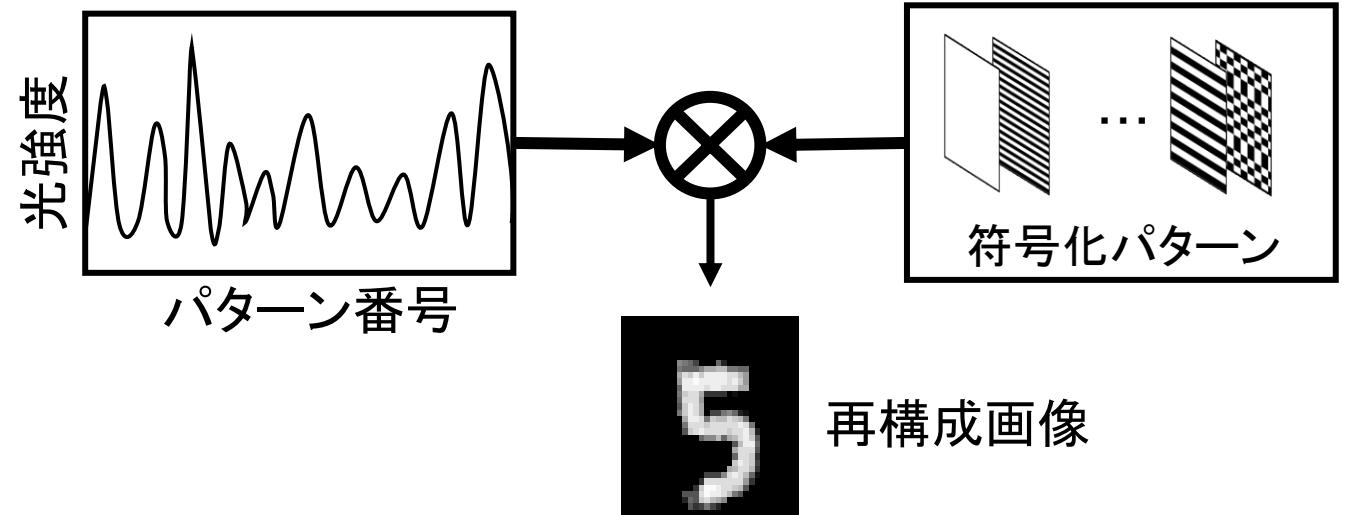

## 今後の予定

- 本手法の有効性を実験で検証する
- 本手法の最適化
- 時系列ノイズに強い再構成モデルの構築
- 再構成画像の多様化・高解像度化



# 付録

## SPIの原理[1]



### 利点

- 検出感度が良い
- スペクトル範囲が広い[2,3]
- 三次元イメージングへの応用[4]

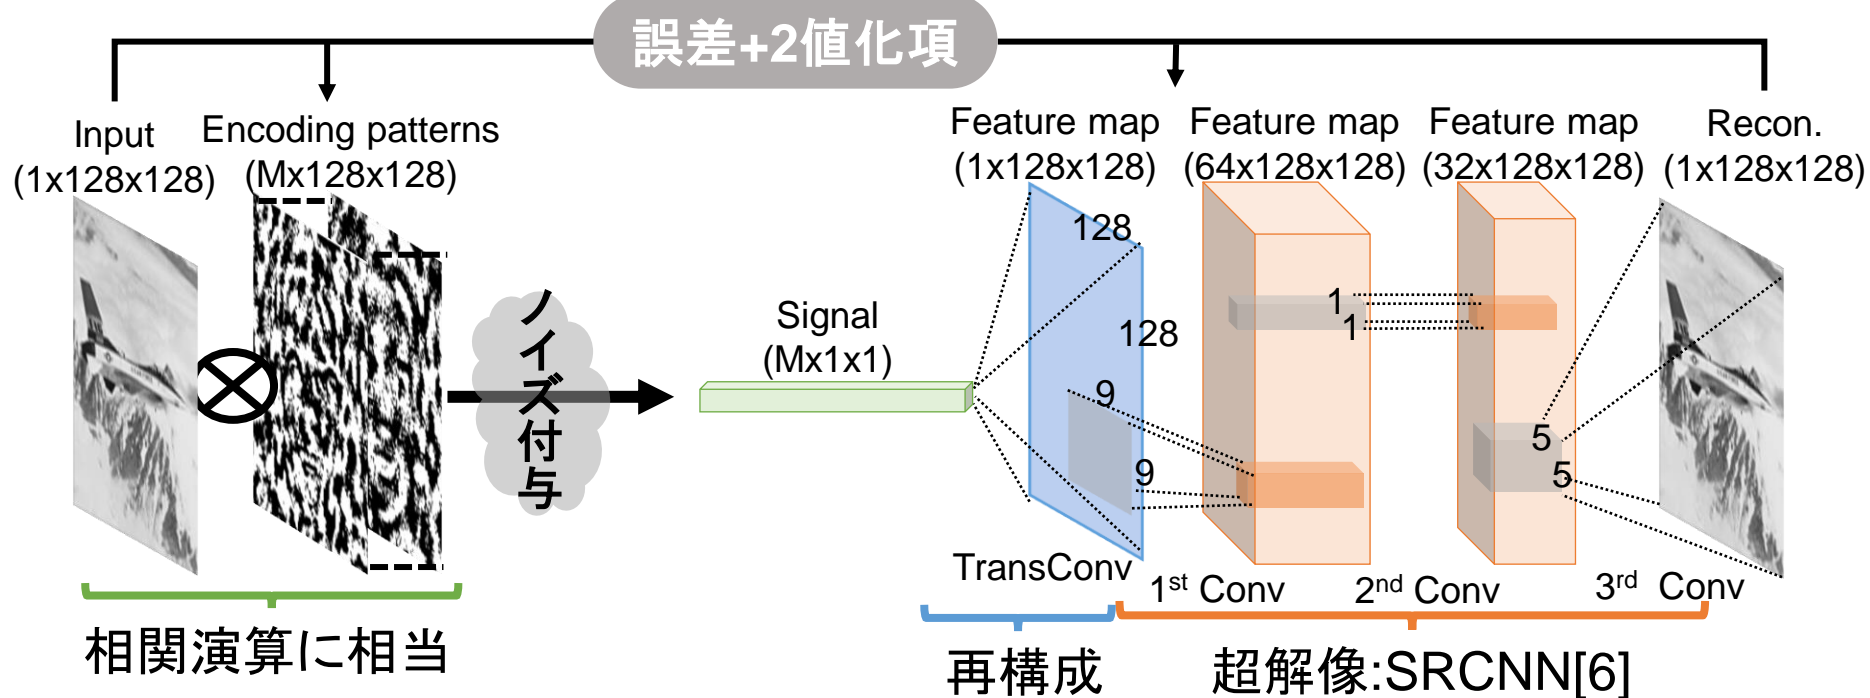
### 欠点

- 高精度なイメージングには大量の光相関信号が必要なために測定時間がかかる
- 強いノイズ環境下での再構成が困難

[1] M. P. Edgar, et al., Nat. Photonics 13, 13–20 (2019). [2] M. Chen, et al., Optics and Photonics Journal, 3, 83-85 (2013).

[3] C. M. Watts, et al., Nature Photonics 8, 605-609 (2014). [4] C.A. Osorio Quero, et al., Review of Scientific Instruments 92, 111501 (2021).

## Deep Convolutional Autoencoder Network(DCAN)[5]



### 利点

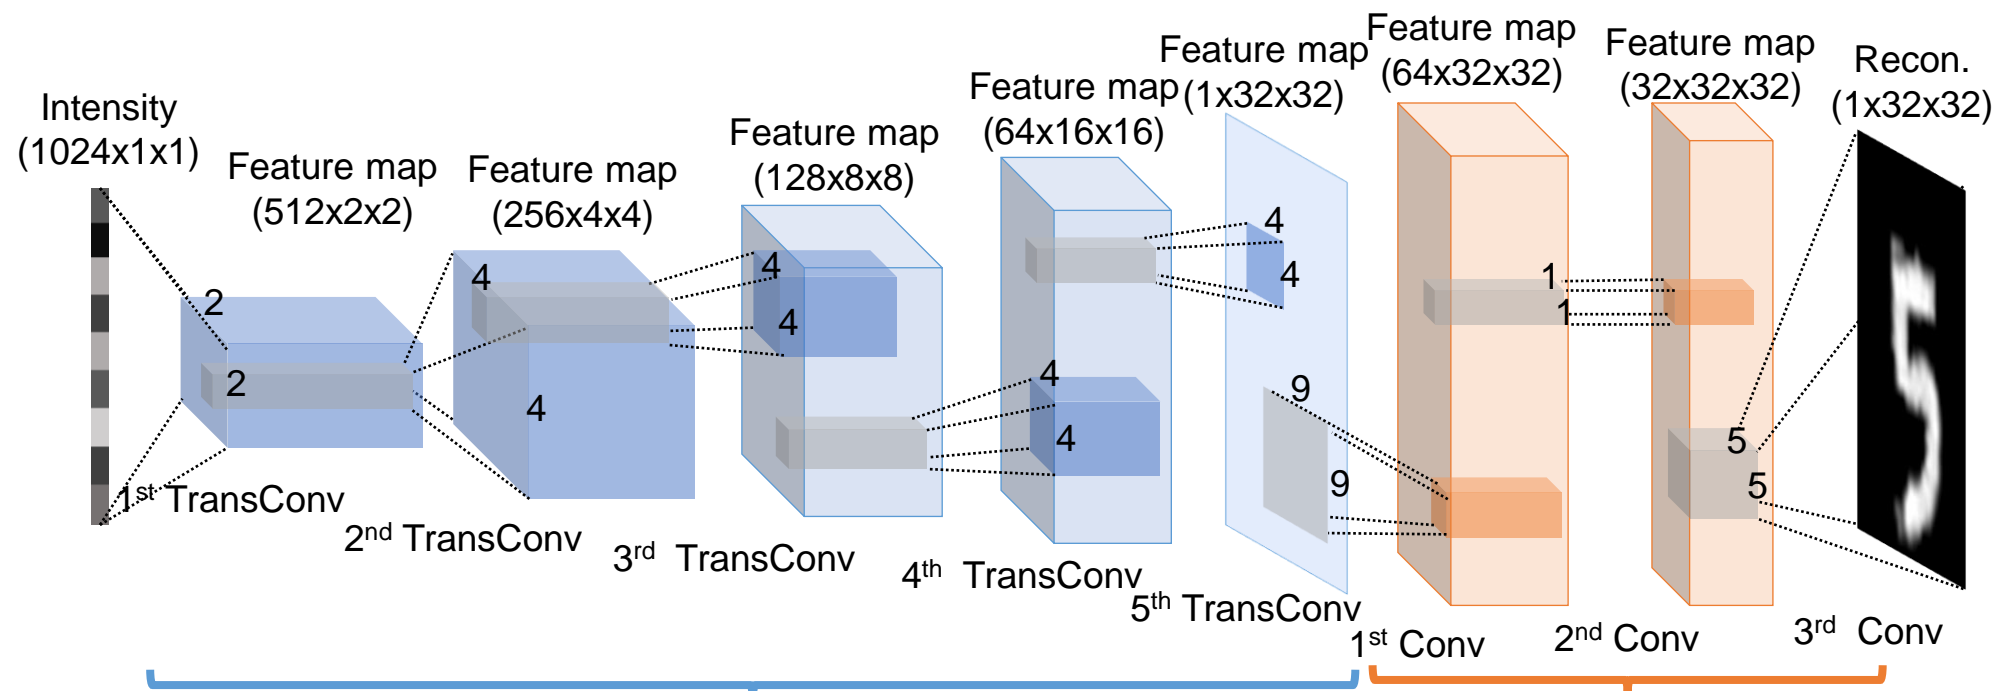
- 入力画像サイズや圧縮率に対して柔軟に対応できる

### 欠点

- 層数が浅いため、複雑なタスクに対応できない



## Deep neural network for TFNS[7,8]



### 特徴

- 再構成部分には、生成モデルの一種であるDCGANのGeneratorを参考にした
- DCANよりも層数が多く、より複雑なタスクの学習が可能→ノイズ耐性が向上

# 2値化のための正則化項の導入

- 深層学習は、誤差逆伝搬法によって損失関数を最小化することで学習を行う
- その損失関数に正則化項 $\Omega$ を加えることで学習パラメータに制限を与える

$$\text{損失関数: } \text{Loss}(I, O) = \text{MSE}(I, O) + \Omega$$

- つまり、2値化するためには学習パラメータ $W$ が”0”または”1”の時に値が最小値をとる関数を正則化項とすれば良い

$$\text{DCANの正則化項: } \Omega_{\{0,1\}} = \sum_l^L \sum_x^X \sum_y^Y (w_{\{x,y\}}^l - 1)^2 (w_{\{x,y\}}^l)^2$$


- 本研究では、さらにホワイtrate $\omega$ を指定できるように以下のような正則化項を用いた

$$\text{本研究の正則化項: } \Omega_{\{\omega\}} = \sum_l^L (c_{\omega} - S\{W^l\})^2$$

$c_{\omega}$ : ホワイtrate $\omega$ で定められた1と0の値を持つ正解行列  
 $S(\cdot)$ : 行列を昇順で並び替える関数

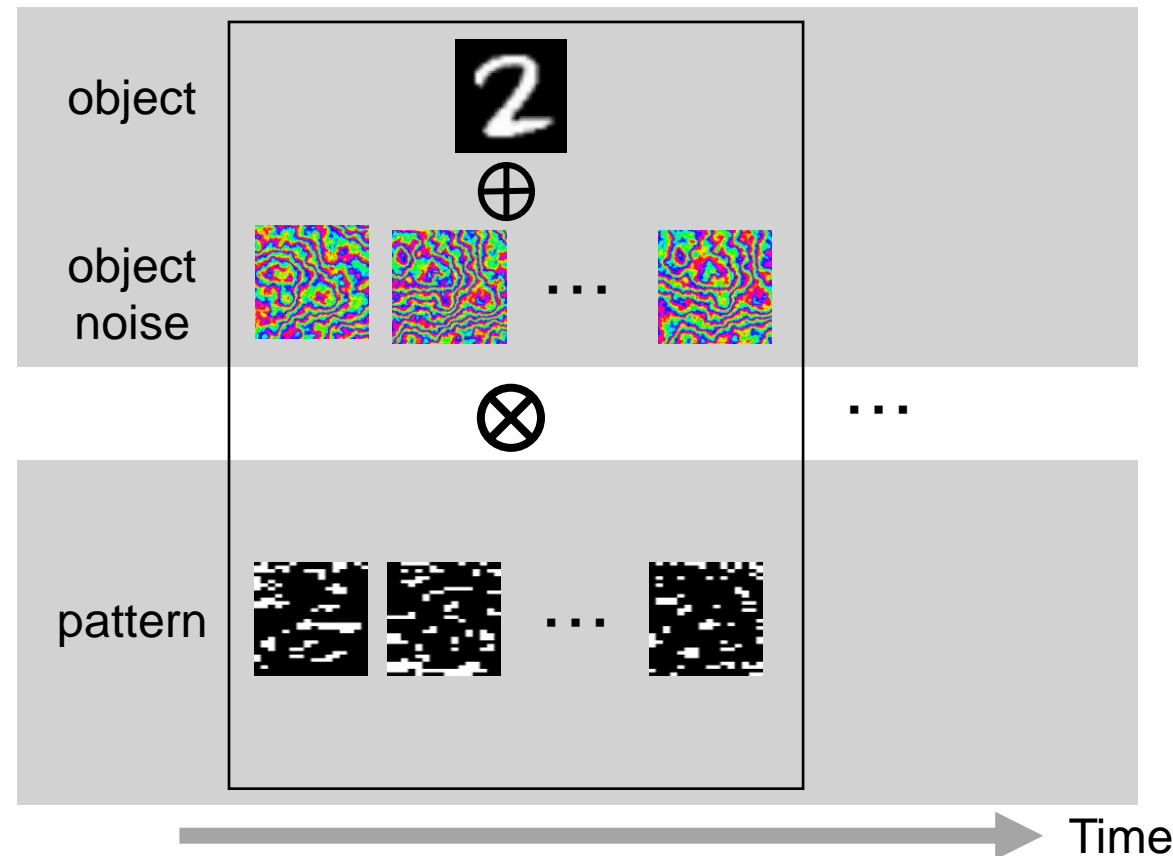
## 01 ガウシアンノイズ

機械的ノイズを想定したガウス分布に基づく強度に作用するノイズ



## 02 大気ゆらぎ


コルモゴロフ乱流理論に則ってモデル化した時間変動&位相に作用するノイズ[5-7]



[5] P. Hickson, The Astronomy and Astrophysics Review **22**, 76 (2014). [6] A. Ishimaru, IEEE Trans. Antennas Propag. **AP-20**, 10, (1972).  
[7] JW. Goodman, *Statistical Optics*, trans. M. Takeda(Tokyo: Maruzen, 1992), pp. 365-466.

# 大気ゆらぎ付与の問題点

コルモゴロフ乱流理論に則って定量化し, 大気ゆらぎを生成した



## フリードパラメータ

- ゆらぎの激しさを決めるパラメータ
- $r_0$  離れた2点の位相差の分散が  $6.88\text{rad}^2$  となる

ピクセルピッチ	5mm
変動速度	20m/s
DMDの表示速度	250 $\mu\text{s}$

■ 欠点 大気ゆらぎの付与をフーリエ面で行うため時間がかかる


Ex) Step 1を同条件で行う場合

6万枚  $\times$  1024パターン  $\times$  900エポック  $\approx$  553億回  
のフーリエ・逆フーリエ変換が必要

Step 1: ガウシアンノイズで汎用的な学習  
Step 2: 大気ゆらぎで光相関信号を取得


# シミュレーション手順

## Step 1. パターン学習 + 事前学習



先ほどと同じガウシアンノイズで学習！

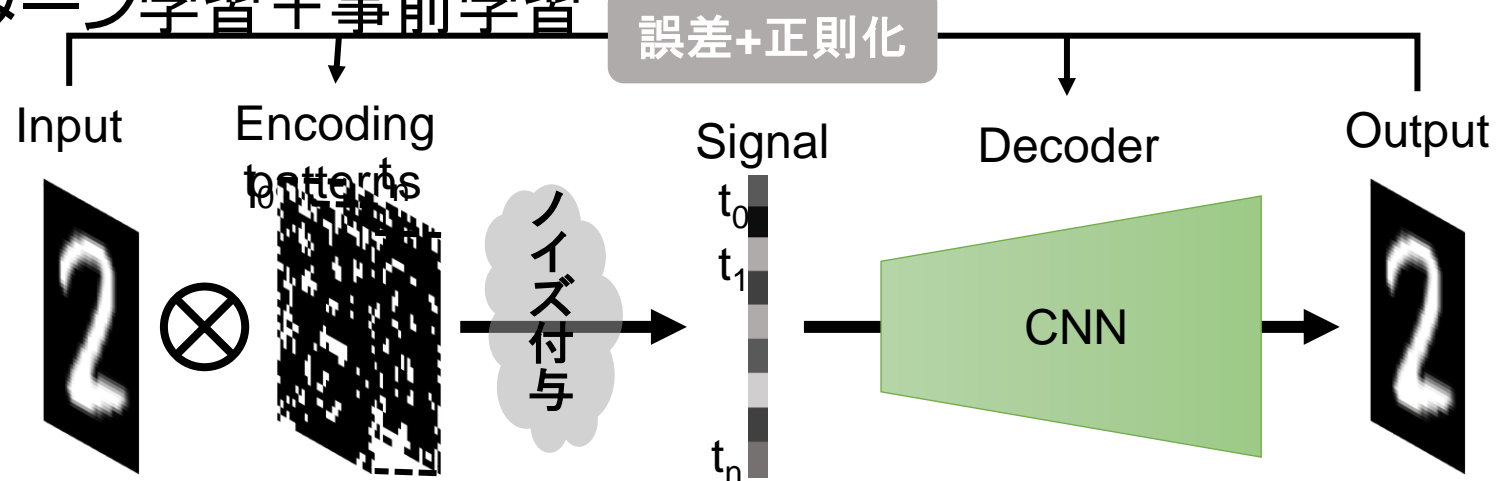
## Step 2. 再構成学習



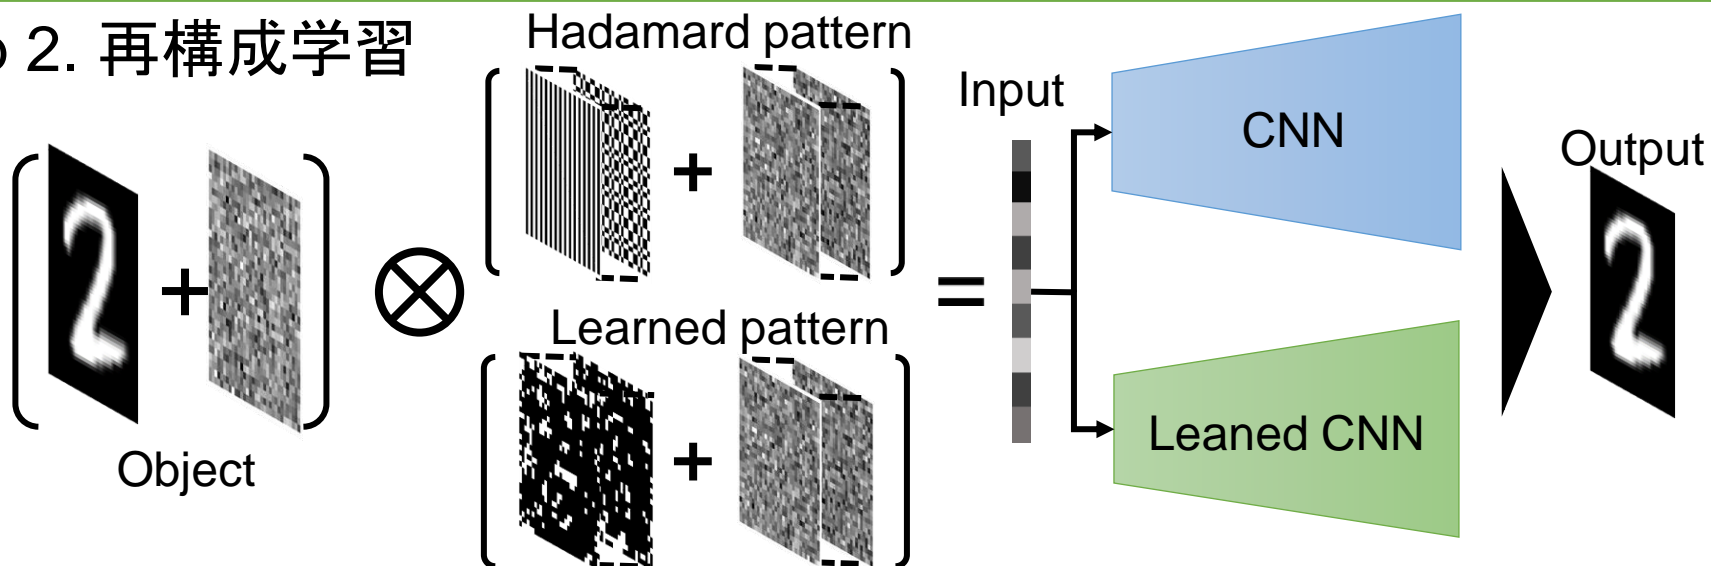
大気ゆらぎでファインチューニング

# シミュレーション手順

## Step 1. パターン学習 + 事前学習



## Step 2. 再構成学習



# シミュレーション条件: ガウシアンノイズ

## パターン学習条件

画像サイズ		32 × 32 pixel
データセット	種類	MNIST
	枚数	60,000 枚
設計パターン枚数		1024 枚
訓練:検証		8:2
学習回数	1段階	700 epoch
	2段階	200 epoch
光信号ノイズ強度		3.0

## 最小二乗法(LS)による再構成式

$$\hat{x} = \arg \min_x \|P'x - s'\|^2$$

$s'$ : ノイズ有りの光信号  
 $P$ : パターン行列  
 $x$ : 正解画像  
 $\hat{x}$ : 再構成画像

## 再構成学習条件の条件

画像サイズ		32 × 32 pixel
データセット	種類	MNIST
	枚数	2,048 枚
符号化 パターン	種類	設計パターン/ アダマール
	枚数	1024 枚
訓練:検証		8:2
学習回数		100 epoch
ノイズ強度		0.5

## 画像評価指標

SSIM	値が1に近いほど再構成精度が高い
RMSE	値が0に近いほど再構成精度が高い

## SPI再構成式

$$x_p = \text{SPI}(H, I) = H^{-1}I$$

測定回数:  $M$

符号化パターン:  $H_m(u, v)$

対象:  $x(u, v)$

光信号:  $I_m = H_m(u, v)x(u, v)$

推定画像:  $x_p$

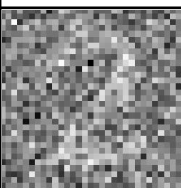
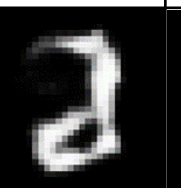


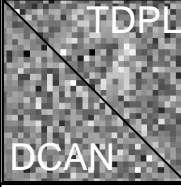
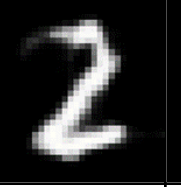

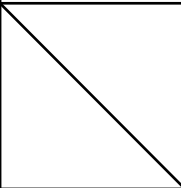


## CGI再構成式


$$x_p = \text{CGI}(H, I) = \langle H_m I_m \rangle - \langle H_m \rangle \langle I_m \rangle$$

$$\langle H_m \rangle = \frac{1}{M} \sum_{m=1}^M H_m$$
$$\langle I_m \rangle = \frac{1}{M} \sum_{m=1}^M I_m$$




# シミュレーション結果：ガウシアンノイズ

	正解 画像	LS	DNN	
			DCAN	TDPL
Hadamard pattern				
		0.144	0.588	0.679
		0.447	0.187	0.169
Learned Pattern				
		Ave. SSIM 0.013\0.014	0.629	0.697
		Ave. RMSE 0.487\0.485	0.177	0.162
Learned pattern + Fine tuning				
			0.753	0.785
			0.143	0.127



(a) SSIM



(b) RMSE